

# **Multimédia**

## **Trabalho Prático nº 2**

### **Music Information Retrieval**

## Objectivo

Pretende-se que o aluno adquira sensibilidade para as questões fundamentais de **Multimedia Information Retrieval**, em particular de sistemas de recomendação de música baseados em conteúdo (**content-based music recommendation systems**).

---

## Planeamento

**Prazo de Entrega:**

**10 de Maio, sexta-feira, 23h59**

**Esforço extra-aulas previsto:** 18h/aluno

**Formato de Entrega:**

- 1) Entrega final (código completo + relatório): InforEstudante
- 2) Notas: Gerar o ficheiro zip, contendo o pdf do relatório, os ficheiros com o código e outros ficheiros que considere relevantes;

**Período de execução:** 6 aulas práticas laboratoriais

**Ritmo de execução esperado para avaliação contínua:**

- Semana 1: alíneas 1 e 2.1
- Semana 2: alínea 2.2
- Semana 3: alínea 3
- Semana 4: alínea 4
- Semana 5 e 6: correcções e relatório

# Trabalho Prático

**Implementação e análise de um sistema de recomendação de música baseado em conteúdo, usando Python.**

1. Preparação.
  - 1.1. Descarregar a base de dados a utilizar (4Q audio emotion dataset, com 900 músicas) do seguinte URL: <http://mir.dei.uc.pt/downloads.html>.
  - 1.2. Analisar a base de dados.
    - 1.2.1. Excertos áudio: ficheiros mp3 (em particular a query fornecida).
    - 1.2.2. Metadados: ficheiro **panda\_dataset\_taffc\_metadata.csv**, colunas Song, Artist, MoodsStrSplit e GenresStr.
  - 1.3. Estudar a framework de processamento áudio *librosa*
    - 1.3.1. Instalar a framework a partir do seguinte URL: <https://librosa.org/> (pip install librosa).  
Será também necessário instalar a framework ffmpeg para leitura de ficheiros .mp3: <https://ffmpeg.org/> (em linux: sudo apt-get install -y ffmpeg)
    - 1.3.2. Executar e analisar o código fonte de base fornecido (ficheiro **mrs.py**).  
Para reprodução de ficheiros áudio, será necessário instalar a biblioteca **sounddevice** (conda install conda-forge::python-sounddevice)
    - 1.3.3. Estudar a documentação da framework librosa, em particular as funções referentes à **extracção de features**: <https://librosa.org/doc/latest/feature.html>.

Sugestão de funções a utilizar nas alíneas seguintes:

- *os.path.isfile*
- *os.listdir*
- *numpy.genfromtxt*
- *numpy.savetxt*
- *numpy.sort*
- *numpy.argsort*
- *numpy.corrcoef*
- *list.split*

2. **Extracção de Features.**
    - 2.1. Extrair features da framework *librosa*.
      - 2.1.1. Para os 900 ficheiros da BD, **extrair as seguintes features** (sugestão: guardar todas as músicas na mesma pasta):
        - Features Espectrais: *mfcc*, *spectral centroid*, *spectral bandwidth*, *spectral contrast*, *spectral flatness* e *spectral rolloff*.
        - Features Temporais: *F0*, *rms* e *zero crossing rate*.
        - Outras features: *tempo*.
- Nota: para validação, as features deverão ser extraídas e guardadas pela ordem indicada.

- Utilize os parâmetros por omissão do librosa ( $sr = 22050$  Hz, mono,  $window\ length = frame\ length = 92.88$  ms e  $hop\ length = 23.22$  ms)

*Nota: são parâmetros por omissão, pelo que não será necessário especificá-los na chamada das funções de extracção de features).*

- 2.1.2. **Calcular as 7 estatísticas** típicas sobre as features anteriores: média, desvio padrão, assimetria (skewness), curtose (kurtosis), mediana, máximo e mínimo (para efeitos de debug, sugere-se a utilização desta ordem). Para o efeito, utilizar a biblioteca `scipy.stats` (e.g., `scipy.stats.skew`).

- Guarde as features num array numpy 2D, com **número de linhas = número de músicas** e **número de colunas = número de features**

- 2.1.3. **Normalizar** as features no intervalo  $[0, 1]$ .

*Sugestão: a função a desenvolver poderá receber tanto os valores mínimo e máximo a utilizar na normalização como calculá-los como determiná-los pela gama de valores da variável em causa.*

- 2.1.4. **Criar e gravar em ficheiro** o array numpy com as features extraídas.

*Nota: a primeira linha do ficheiro deverá conter o mínimo de cada feature; a segunda linha deverá conter o máximo de cada feature; as linhas seguintes devem conter os feature vectors de cada música.*

- 2.1.5. **Validar os resultados** obtidos com base nos exemplos fornecidos juntamente com este enunciado.

- 2.2. Implementar a feature **spectral centroid** de raiz. Neste ponto, não é permitido utilizar o librosa nem qualquer outra biblioteca, à excepção do `scipy` e `numpy`, e.g., `scipy.fftpack`.

- 2.2.1. Deverá desenvolver o código Python/numpy para extrair a feature spectral centroid (SC), usando a mesma parametrização usada na alínea 2.1. Para tal, deverá basear-se nos **materiais teóricos da disciplina**, em particular os slides do capítulo de Multimedia Information Retrieval.

- 2.2.2. **Comparar os resultados obtidos com os resultados do librosa**, usando as seguintes métricas de erro: **coeficiente de correlação de Pearson** e **RMSE**. Sugestão de debug: visualizar os dois arrays de SC (do librosa e o resultado desta alínea); de notar que a extracção de features do librosa tem um **atraso de 2 janelas**.

- 2.2.3. **Guardar em ficheiro** os resultados das métricas de erro (ficheiro csv com 900 linhas e 2 colunas, uma para cada métrica).

- 2.2.4. **Validar os resultados** obtidos com base nos exemplos fornecidos juntamente com este enunciado.

3. Implementação de **métricas de similaridade**.

- 3.1. Desenvolver o código Python/numpy para **calcular as seguintes métricas de similaridade** (poderá também utilizar funções pré-existentes):

- 3.1.1. Distância Euclidiana
- 3.1.2. Distância de Manhattan
- 3.1.3. Distância do Coseno

- 3.2. Para a query:

- 3.2.1. **Extrair, calcular as 7 estatísticas e normalizar as features correspondentes.**
- 3.2.2. **Criar e gravar em ficheiro** 3 matrizes de similaridade, um para cada métrica de distância utilizada.

- 3.3. Para a query, **criar os 3 rankings de similaridade**, um para cada métrica de distância utilizada. Considere apenas recomendações de **10 músicas**.
- 3.4. **Validar os resultados** obtidos com base nos exemplos fornecidos juntamente com este enunciado.
- 3.5. 📄 **Apresentar, comparar e discutir os resultados.**

#### 4. Avaliação.

##### 4.1. Avaliação objectiva.

- 4.1.1. **Obter o ranking** das 10 músicas recomendadas com base na correspondência com os **metadados** seguintes: artista, género e emoção (colunas Artist, MoodsStrSplit e GenresStr dos ficheiros de metadados ***panda\_dataset\_taffc\_metadata.csv*** e ***query\_metadata.csv***). Por cada item coincidente, adicionar um ponto à qualidade da música alvo, e.g., se tanto a query como o alvo tiverem género = jazz e emoção = happy, a qualidade do alvo será 2. Para o efeito, criar e gravar a matriz de similaridade baseada em contexto (i.e., nos metadados).
- 4.1.2. Para cada um dos rankings determinados em 3.3, calcular a métrica ***precision***, assumindo como relevantes as músicas devolvidas em 4.1.1 (metadados).
- 4.1.3. **Validar os resultados** obtidos com base nos exemplos fornecidos juntamente com este enunciado.
- 4.1.4. 📄 **Apresentar, comparar e discutir os resultados.**

##### 4.2. Avaliação subjectiva.

- 4.2.1. Para cada um dos **rankings construídos usando as 3 métricas de distâncias**, **avaliar a qualidade de cada uma das 10 recomendações**, com base na seguinte escala de Likert ": 1 – Muito Má; 2 – Má; 3 – Aceitável; 4 – Boa; 5 – Muito Boa. Cada elemento do grupo deverá efectuar individualmente a avaliação da recomendação.
  - a) Calcular a **média e o desvio-padrão** de cada música recomendada, com base nas avaliações de todos os membro do grupo de trabalho, assim como a média e o desvio-padrão global (para cada ranking).
  - b) Definindo um **score mínimo de 2.5** para “recomendação relevante”, calcular a ***precision*** resultante.
- 4.2.2. Para o **ranking de similaridade com base nos metadados**, **avaliar a qualidade de cada uma das 10 recomendações**, com base na escala de Likert anterior. Cada elemento do grupo deverá efectuar individualmente a avaliação da recomendação.
  - a) Calcular a **média e o desvio-padrão** de cada música recomendada, com base nas avaliações de todos os membro do grupo de trabalho, assim como a média e o desvio-padrão global.
  - b) Definindo um **score mínimo de 2.5** para “recomendação relevante”, calcular a ***precision*** resultante.
- 4.2.3. 📄 **Apresentar, comparar e discutir os resultados.**